D3 — Matemática e Estatística para Inteligência Artificial

Encontro 1 de 4 · primeira sexta

B1 — Por que esta disciplina existe

Matemática e Estatística para IA

1. Vetores, espaços e significado
2. Hoje: como um texto vira número, e o que "parecido" quer dizer

Boa noite. A D2 terminou com um agente funcionando e um número na tela: tantos acertos em trinta casos. Esta disciplina existe para transformar aquele número em evidência. O mercado está cheio de gente que monta um agente e diz que ficou bom; quase ninguém sabe provar que ficou, nem dizer se a versão nova é melhor que a antiga ou se a diferença é acaso da amostra. É essa competência que separa o egresso deste curso.

O que vamos ver hoje

1. Uma pergunta que fica aberta até o segundo sábado
2. Vetores: como o significado vira geometria
3. Matrizes: transformações, e a fórmula central dos Transformers
4. O laboratório dos vetores do seu próprio domínio

A noite tem três paradas. A primeira é curta e existe para instalar a pergunta que organiza a disciplina inteira. A segunda é a mais longa e trata de vetores, com o laboratório sobre o domínio de cada um. A terceira sobe para matrizes e termina escrevendo, peça por peça, a fórmula que está no coração dos modelos de linguagem. Este mapa reaparece a cada virada de bloco.

Bloco 1 — Por que esta disciplina existe

Este bloco não ensina técnica nenhuma. Ele existe para que a turma saia daqui sabendo qual pergunta está sendo respondida nas próximas trinta horas, e por que ela não se responde com opinião. Quem entende a pergunta atravessa a disciplina com paciência para a álgebra e para a probabilidade.

Duas versões do mesmo agente

Versão	Acertos em 30 casos	Taxa
A — a linha de base da D2	23	76,7%

B — com uma regra a mais	25	83,3%

Aqui estão duas versões do mesmo agente, avaliadas sobre os mesmos trinta casos. A segunda acertou dois a mais. A pergunta é direta: a versão B é melhor que a versão A? Vale a pena substituir uma pela outra em produção? A resposta intuitiva é sim, e a resposta intuitiva é onde quase todo projeto de IA erra. Guardem a resposta de vocês; ela será confrontada no segundo sábado, com ferramenta.

Por que a resposta intuitiva não serve

1. Dois acertos a mais podem ser competência, ou podem ser sorte
2. A mesma amostra em outra semana daria outro número
3. Sem incerteza declarada, um número não é evidência
4. Decidir com ele é apostar, não medir

O valor de 83,3% saiu de trinta casos, e trinta casos são uma amostra. Se outros trinta casos do mesmo domínio tivessem sido escolhidos, os dois números teriam mudado — talvez pouco, talvez o suficiente para inverter a ordem. Um número sem incerteza declarada não permite decisão defensável. A disciplina existe para dar a essa frase um procedimento em vez de um sentimento.

Os três eixos, e para que cada um serve

Eixo	Pergunta que responde	Onde é usado
Álgebra linear	Como um texto vira vetor, e o que "parecido" significa	D6, D7, D8, D9
Cálculo e otimização	Como um modelo aprende, e por que às vezes não aprende	D5, D6, D8
Probabilidade e inferência	Como sei que melhorou, e não que tive sorte	D5, D7, D9, D10, D12

A disciplina tem três eixos e eles não têm o mesmo peso. O terceiro é o mais importante e recebe a maior fatia de carga, porque é ele que produz o artefato que seis disciplinas seguintes vão consumir. Os dois primeiros existem para que o terceiro faça sentido, e para que a turma pare de ver embeddings e treino como caixas-pretas. Hoje é o primeiro eixo inteiro.

O que você traz da D2, e onde usamos

O que você tem	Onde entra aqui
A métrica primária, com definição	É sobre ela que se calcula a incerteza

operacional	
O valor medido sobre ≥ 30 casos	É o número que ganha intervalo, no E3
O conjunto de casos rotulado	A mesma amostra, reamostrada e testada
A tabela comparativa de busca	Comparar buscas também exige dizer se a diferença é real

Nada aqui recomeça. A D2 entregou uma medida de desempenho declarada e um valor medido sobre casos rotulados; a D3 pega exatamente esses artefatos e faz a pergunta que a D2 não tinha ferramenta para responder. Quem chegou sem o conjunto de casos ainda consegue acompanhar as aulas, mas não consegue fazer a Atividade Orientada sobre o próprio domínio — e é ela que constrói metade da entrega final.

O que você leva daqui: o protocolo

1. Um documento que diz como o seu projeto será avaliado
2. Métrica, unidade experimental, tamanho de amostra, teste, critério
3. Consumido por D5, D7, D9, D10, D11 e D12
4. Sem ele, ninguém consegue julgar se o seu agente melhorou

O produto final desta disciplina não é uma prova nem um notebook: é um documento normativo do projeto de cada um, o protocolo de avaliação. Ele declara, antes de qualquer resultado, como a qualidade do sistema será medida e o que fará alguém trocar uma versão pela outra. Seis disciplinas o consomem sem recriá-lo, e a D12 audita o que foi construído contra o que foi especificado. Escrever esse documento é a entrega final, e ele começa a ser construído já no próximo laboratório.

B2 — Vetores e a geometria do significado

Bloco 2 — Vetores e a geometria do significado

Este bloco responde à primeira pergunta prática do curso: como um texto vira algo que um computador compara. A resposta é geométrica, e a geometria é mais simples do que a notação sugere. Ao fim do bloco, cada um vai ter ordenado frases do próprio domínio por similaridade e olhado para o resultado com desconfiança produtiva.

O que é um vetor, operacionalmente

1. Uma lista ordenada de números
2. Cada posição é uma dimensão, e a ordem importa
3. Em IA, tipicamente centenas ou milhares de posições
4. O mesmo objeto matemático serve a pixels, preços e frases

Um vetor é uma lista ordenada de números, e é só isso. O que muda entre aplicações é o que cada posição representa e quantas posições existem. Um vetor de três posições descreve um ponto no espaço; um de mil e quinhentas descreve uma frase, num espaço que ninguém consegue desenhar mas cujas regras são as mesmas. Toda a intuição que construirmos em duas dimensões continua valendo em mil e quinhentas, com uma exceção importante que veremos no fim do bloco.

Um vetor não significa nada sozinho

1. O número de uma posição não tem interpretação isolada
2. O que existe é a posição relativa entre vetores
3. Comparar é a única operação que produz sentido
4. Por isso a pergunta é sempre "parecido com o quê"

É comum alguém abrir um vetor de mil e quinhentas posições e tentar interpretar a terceira delas. Não há o que interpretar: as dimensões de um espaço aprendido não têm nome nem significado individual. O que carrega significado é a relação entre vetores — quais estão próximos, quais estão distantes, em que direção um está em relação ao outro. Toda a utilidade prática dessa representação vem de comparação, nunca de leitura.

Norma: o tamanho de um vetor

De um lado: - Norma L2: raiz da soma dos quadrados
- É a distância até a origem
- A noção usual de comprimento. Do outro: - Norma L1: soma dos valores absolutos
- Distância percorrida em ruas quadriculadas
- Menos sensível a uma posição isolada muito grande.

A norma responde a quanto um vetor mede. A L2 é a que corresponde à intuição de comprimento, com o teorema de Pitágoras estendido a quantas dimensões existirem. A L1 soma os deslocamentos em cada eixo separadamente, e por isso uma posição extrema pesa menos nela do que na L2. A escolha entre as duas reaparece na D5, quando as mesmas duas fórmulas passam a servir de penalidade num modelo.

Normalizar, e por que quase sempre se normaliza

1. Dividir o vetor pela própria norma L2
2. O resultado tem comprimento 1 e mantém a direção
3. Compara-se direção sem que o tamanho interfira
4. Frase longa deixa de parecer "mais" que frase curta

Normalizar é dividir cada posição do vetor pelo comprimento dele, o que produz um vetor de comprimento um apontando para a mesma direção. O motivo prático é direto: em texto, o comprimento do vetor costuma refletir o tamanho do trecho, e não o assunto dele. Sem normalizar, um parágrafo inteiro tende a parecer mais relevante que uma frase curta sobre o mesmo tema, o que é um defeito de medida e não uma descoberta. É a primeira decisão de modelagem escondida numa operação aritmética.

Produto escalar: a conta

(python)

```python
import numpy as np

a = np.array([2.0, 1.0, 0.0])
b = np.array([1.0, 3.0, 1.0])

produto = np.dot(a, b)          # 2*1 + 1*3 + 0*1 = 5.0
norma_a = np.linalg.norm(a)     # sqrt(4 + 1 + 0)
unitario = a / norma_a          # comprimento 1

print(produto, norma_a, np.linalg.norm(unitario))
```

O produto escalar multiplica as posições correspondentes de dois vetores e soma tudo. São três linhas de aritmética e uma função pronta na biblioteca. A conta não é o ponto; o ponto é o que esse número significa, que é o próximo slide. Reparem que a norma é o produto escalar de um vetor com ele mesmo, seguido de raiz — a mesma operação serve às duas coisas.

Produto escalar: o que ele significa

1. Mede o quanto dois vetores apontam para a mesma direção
2. Positivo: direções concordantes
3. Zero: perpendiculares, sem relação linear
4. Negativo: direções opostas
5. Cresce também com o tamanho dos dois vetores

Geometricamente, o produto escalar é o comprimento de um vetor multiplicado pela projeção do outro sobre ele. Em português: mede o quanto os dois apontam para o mesmo lado, temperado pelo tamanho de cada um. Esse duplo papel é justamente o problema — um produto escalar alto pode significar direções muito parecidas ou apenas vetores muito compridos. Separar as duas coisas é o que a similaridade de cosseno faz.

Similaridade de cosseno

1. Produto escalar dividido pelo produto das duas normas
2. Equivale ao cosseno do ângulo entre os vetores
3. Varia de −1 a 1, e o tamanho deixa de influenciar
4. Em vetores já normalizados, é o próprio produto escalar

Dividir o produto escalar pelas duas normas remove a influência do comprimento e deixa apenas a direção, o que dá exatamente o cosseno do ângulo entre os dois vetores. Um valor perto de um indica direções quase iguais; perto de zero, independência; negativo, direções opostas. Esta é a medida que sustenta busca semântica, recuperação aumentada e boa parte do que a turma vai construir na D7 e na D9. Se os vetores já foram normalizados, a divisão é por um e a conta se reduz ao produto escalar — que é por isso que os sistemas de recuperação normalizam tudo na entrada.

Cosseno ou distância euclidiana?

De um lado: - Cosseno olha a direção
- Ignora magnitude
- Padrão para texto e recuperação. Do outro: - Euclidiana olha a posição
- Magnitude importa
- Faz sentido quando a escala é comparável.

As duas medidas respondem a perguntas diferentes e a escolha não é estilística. Em texto, o comprimento do vetor carrega tamanho do trecho, não assunto, e por isso a direção é o que interessa. Em dados onde cada dimensão tem unidade conhecida e escala comparável, a distância euclidiana diz algo real sobre o quanto dois casos diferem. Um detalhe útil: sobre vetores normalizados, as duas medidas produzem a mesma ordenação, o que explica por que muita gente as confunde sem sofrer consequência.

Laboratório 01 — os vetores do meu domínio

1. Vetores já calculados para frases do seu domínio, sem rede
2. Calcular similaridade de cada par e ordenar
3. Comparar cosseno com euclidiana, com e sem normalizar
4. Registrar dois pares cuja ordem surpreendeu

Laboratório pronto quando: ordenação por cosseno impressa, e dois pares anotados com o motivo da surpresa

O laboratório usa vetores pré-calculados, distribuídos no pacote, e não chama nenhum serviço pela rede. A tarefa é ordenar as frases por similaridade e olhar para a ordenação com desconfiança: procurar os pares que ficaram próximos sem razão aparente e os que ficaram distantes quando deveriam estar juntos. O produto do laboratório não é o código rodando, que é curto, mas as duas observações escritas sobre a ordem que saiu.

Para fazer: Abra o pacote D3-01 e rode o esqueleto sobre o arquivo de vetores do seu domínio; se o seu não estiver lá, use o conjunto de reserva.

Laboratório 01 — durante o trabalho

1. Normalizar mudou alguma ordem? Qual?
2. Há par próximo que não deveria estar próximo?
3. Há par distante que deveria estar junto?
4. Anote os dois casos: eles voltam na D7

Laboratório pronto quando: os dois pares anotados, um próximo sem razão e um distante sem razão

Enquanto o laboratório corre, vale perseguir três perguntas. A primeira é mecânica: normalizar alterou a ordenação, e em que pares. As outras duas são de julgamento, e são as que importam — todo espaço vetorial aprendido tem regiões onde ele erra, e encontrá-las cedo é o que impede alguém de confiar cegamente em busca semântica mais adiante. Os pares anotados aqui voltam na D7, quando a turma montar o próprio índice de recuperação.

O que a ordenação costuma revelar

1. Frases com as mesmas palavras e sentidos opostos ficam próximas
2. Negação quase não afasta os vetores
3. Jargão do domínio pode ficar mal representado
4. Proximidade é sobre assunto, não sobre verdade

O achado mais comum é que negação separa muito pouco: "o equipamento falhou" e "o equipamento não falhou" costumam ficar vizinhos, porque compartilham quase todo o vocabulário e o assunto é o mesmo. O segundo é o jargão do domínio, que o modelo que gerou os vetores pode nunca ter visto o suficiente. A conclusão prática atravessa o curso: proximidade vetorial indica assunto parecido, e jamais afirmação equivalente. Quem confunde as duas coisas constrói um sistema de recuperação que devolve exatamente o oposto do que foi perguntado.

A maldição da dimensionalidade

1. Em muitas dimensões, as distâncias entre pontos se aproximam
2. O mais próximo e o mais distante passam a se parecer
3. Intuição de duas dimensões deixa de valer aqui
4. Por isso se usa cosseno, e se reduz dimensão para ver

Conforme o número de dimensões cresce, os pontos de um conjunto tendem a ficar todos a distâncias parecidas uns dos outros, e a diferença entre o vizinho mais próximo e o mais distante encolhe. É a única parte da intuição geométrica que não sobrevive à alta dimensão, e é a razão de a distância euclidiana pura ser pouco informativa em espaços de mil e quinhentas dimensões. Duas consequências práticas: prefere-se comparar direção, e reduz-se a dimensão antes de tentar enxergar qualquer coisa — que é o que a janela de exploração do primeiro sábado vai fazer.

Onde isto reaparece no curso

1. D6: os vetores deixam de ser dados e passam a ser aprendidos
2. D7: o índice de recuperação, construído sobre similaridade
3. D8: representação de texto dentro do modelo de linguagem
4. D9: recuperação aumentada, que é busca por cosseno com contexto

Similaridade de cosseno é, provavelmente, a fórmula desta disciplina que cada um vai escrever mais vezes na vida profissional. Ela sustenta o índice da D7, a recuperação da D9 e boa parte do que se chama de busca semântica no mercado. Quem entende que ela mede direção, e que direção é assunto e não verdade, evita a classe de erro mais cara desses sistemas.

B3 — Matrizes como transformações

Bloco 3 — Matrizes como transformações

O bloco anterior tratou de um vetor por vez. Este trata do que acontece quando

se aplica a mesma operação a muitos vetores de uma vez, que é o que uma matriz faz. Ao fim, teremos escrito a fórmula que está no coração dos modelos de linguagem e verificado que cada peça dela já apareceu nesta noite.

Matriz como função linear

1. Uma matriz recebe um vetor e devolve outro vetor
2. É uma função, e uma função de tipo restrito
3. Preserva soma e multiplicação por número
4. Toda a álgebra linear vem dessas duas propriedades

A leitura mais útil de uma matriz não é a de tabela de números, e sim a de função: entra um vetor, sai outro. O que a torna linear são duas garantias — transformar a soma de dois vetores dá o mesmo que somar os transformados, e multiplicar um vetor por um número antes ou depois da transformação dá o mesmo resultado. Parece pouco, e é o que permite compor transformações e resolver sistemas inteiros de uma vez.

Multiplicação, e a regra da forma

(python)

```
import numpy as np

M = np.array([[2.0, 0.0],
              [0.0, 3.0]])       # forma (2, 2)
v = np.array([1.0, 1.0])         # forma (2,)

print(M @ v)                     # [2. 3.] — forma (2,)

lote = np.array([[1.0, 1.0],
                 [0.0, 2.0]])    # 2 vetores, forma (2, 2)
print(lote @ M.T)                # transforma os dois de uma vez
```

Multiplicar matriz por vetor aplica a transformação; multiplicar matriz por matriz compõe duas transformações numa só. A regra que governa tudo é a das formas: o número de colunas da primeira precisa bater com o número de linhas da segunda. Noventa por cento dos erros de quem começa em aprendizado profundo são erros de forma, e a leitura do erro é sempre a mesma pergunta — o que entrou, com que forma, e o que a operação esperava.

Rotação, escala e projeção

Transformação	O que faz	Onde aparece
Escala	Estica ou encolhe cada eixo	Normalização de atributos
Rotação	Gira o espaço, preserva comprimentos	Mudança de base, PCA
Projeção	Achata sobre um subespaço	Redução de dimensão

	menor	

Três transformações dão quase toda a intuição necessária. A escala multiplica cada eixo por um fator, a rotação gira o espaço sem alterar comprimentos, e a projeção descarta parte da informação ao achatar o espaço sobre um subconjunto de direções. A projeção é a mais importante para o curso, porque é o que acontece toda vez que se reduz a dimensão de um conjunto de vetores para visualizar ou para acelerar uma busca. E toda projeção descarta algo: a pergunta que fica é sempre o quê.

Identidade, inversa e transposta

De um lado: - Identidade: não muda nada
- Inversa: desfaz a transformação
- Nem toda matriz tem inversa. Do outro: - Transposta: troca linhas por colunas
- Aparece em quase toda fórmula de rede neural
- Barata, e frequentemente só uma leitura diferente.

A identidade é o elemento neutro: aplicá-la devolve o vetor intacto. A inversa desfaz o que a matriz fez, e a existência dela não é garantida — uma matriz que projeta, e portanto descarta informação, não tem como ser desfeita. A transposta troca linhas por colunas e é a operação mais frequente nas fórmulas que a turma vai ler na D6, geralmente para fazer as formas baterem numa multiplicação.

Posto: quanta informação sobrevive

1. Número de direções realmente independentes na matriz
2. Posto baixo significa colunas que se repetem em disfarce
3. Uma matriz de posto baixo comprime sem perder muito
4. É a ideia por trás de técnicas de ajuste eficiente

O posto conta quantas direções independentes uma matriz de fato usa. Se três colunas podem ser escritas como combinação de duas, o posto é dois, e a terceira coluna não carrega informação nova. Isso tem consequência prática direta: uma matriz grande com posto baixo pode ser guardada e aplicada de forma muito mais barata. É exatamente essa observação que sustenta as técnicas de ajuste fino eficiente que aparecem na D6 e na D8.

Autovalores e autovetores

1. Autovetor: direção que a matriz não gira, só estica
2. Autovalor: o quanto ela estica nessa direção
3. Revelam o comportamento essencial da transformação
4. Autovalor grande indica direção de maior variação

Toda transformação linear tem, em geral, direções especiais que ela não gira: aplica a matriz e o vetor continua apontando para o mesmo lugar, apenas mais comprido ou mais curto. Essas direções são os autovetores, e o fator de esticamento é o autovalor. Conhecê-los é conhecer o comportamento essencial da

transformação sem precisar aplicá-la a todos os vetores possíveis. Nenhuma demonstração é exigida nesta disciplina; o que se exige é reconhecer a ideia quando ela aparecer com outro nome.

A ligação com a redução de dimensão

1. Direções de maior variação são as mais informativas
2. Manter as primeiras e descartar o resto é comprimir
3. É a ideia da análise de componentes principais
4. Retomada na D5, e usada no primeiro sábado

Se as direções com maior autovalor são aquelas em que os dados mais variam, guardar apenas as primeiras preserva quase toda a estrutura gastando muito menos espaço. Essa é a ideia da análise de componentes principais, tratada em profundidade na D5 e usada já no primeiro sábado para conseguir enxergar em duas dimensões um conjunto de vetores de mil e quinhentas. Vale a advertência de sempre: ao descartar direções, descarta-se informação, e a visualização que sai é uma sombra do espaço real, não o espaço.

Tensores, e a convenção de forma

1. Tensor: a mesma ideia com mais de dois índices
2. Convenção usual: lote × posição × dimensão
3. Ler a forma resolve a maioria dos erros de código
4. É vocabulário de D6 em diante, não conteúdo novo

Um tensor é a generalização de vetor e matriz para mais índices, e para os fins deste curso não há teoria nova a aprender. O que interessa é a convenção de forma que a turma vai encontrar em todo código de aprendizado profundo: a primeira posição costuma ser o lote de exemplos, a segunda a posição dentro da sequência, e a terceira a dimensão da representação. Saber ler essa tripla é o que permite depurar em minutos o que de outro modo leva horas.

Onde a matriz aparece numa rede neural

1. Cada camada densa é uma multiplicação de matriz mais deslocamento
2. Os pesos aprendidos são as posições dessa matriz
3. Treinar é procurar as posições que funcionam
4. A não linearidade entra entre uma camada e a seguinte

Uma camada densa de rede neural é, literalmente, um vetor multiplicado por uma matriz somado a um vetor de deslocamento. Os pesos que o treino ajusta são as posições dessa matriz, e nada mais. O que impede a rede inteira de colapsar numa única matriz é a função não linear aplicada entre as camadas — sem ela, compor transformações lineares dá outra transformação linear, e a profundidade não compraria nada. Amanhã veremos como essas posições são encontradas.

A fórmula central dos Transformers

1. Q, K e V são três matrizes obtidas do mesmo texto

2. QK^T é produto escalar entre todos os pares
3. Dividir por $\sqrt{d}$ controla a escala dos números
4. softmax transforma os valores numa distribuição
5. Multiplicar por V é fazer uma média ponderada

Esta é a operação no coração de todo modelo de linguagem atual, e ela cabe numa linha. Q, K e V são três projeções do mesmo texto, obtidas com três matrizes aprendidas. O produto QK^T calcula o produto escalar entre cada par de posições, ou seja, o quanto cada posição do texto tem a ver com cada outra. A divisão por raiz de d evita que os números cresçam demais quando a dimensão é grande. A softmax converte esses valores numa distribuição que soma um, e a multiplicação final por V produz, para cada posição, uma média ponderada das demais.

Cada peça dela já apareceu hoje

Peça da fórmula	O que é	Visto no slide
Q, K, V	Vetores projetados por matrizes	Matriz como função
QK^T	Produto escalar entre todos os pares	Produto escalar
$\div \sqrt{d}$	Ajuste de escala em alta dimensão	Norma e dimensionalidade
softmax	Vira distribuição que soma 1	Prévia do primeiro sábado
$\cdot V$	Média ponderada dos vetores	Combinação linear

Vale olhar a tabela linha por linha. Não há nesta fórmula uma única operação que não tenha aparecido nesta noite: são produtos escalares, uma normalização de escala, uma conversão em distribuição e uma média ponderada. A dificuldade dos modelos de linguagem não está na álgebra da atenção, que é elementar; está na escala, no treino e nos dados. Quem sai daqui hoje já entende a fórmula central dos Transformers — e essa frase é literal, não motivacional.

Onde isto reaparece no curso

1. D5: componentes principais, e regressão como álgebra linear
2. D6: cada camada, cada forma de tensor, cada transposta
3. D8: a atenção de novo, agora por dentro
4. D9: projeções para acelerar busca em índices grandes

O bloco de hoje é a base de leitura de tudo o que vem em aprendizado profundo e em modelos de linguagem. Nenhuma dessas disciplinas vai reensinar matriz, posto ou autovetor; elas assumem que a turma lê essas palavras sem parar. É por isso que a disciplina começa por aqui.

Amanhã, e o que fechar hoje

1. Amanhã: derivadas, gradiente e a descida implementada à mão
2. Depois: estatística descritiva e probabilidade, com o seu dado
3. Feche o laboratório 01 e anote os dois pares que surpreenderam
4. Traga o conjunto de casos rotulado da D2

O primeiro sábado é longo e usa o que foi feito hoje. Pela manhã, cálculo e otimização, com a descida de gradiente escrita à mão para que ninguém precise acreditar em ninguém. À tarde, estatística descritiva e probabilidade sobre o conjunto de dados de cada um. Quem chegar sem o laboratório 01 fechado consegue acompanhar, mas perde o encaixe com a janela de exploração do fim do dia.

Para fazer: Feche o laboratório 01 hoje e deixe o conjunto de casos da D2 acessível na sua máquina — o primeiro sábado usa os dois.